

Integração da Arquitetura MotionNet ao Sistema CARMEN-LCAD para Predição Espaço-Temporal de Grades de Ocupação BEV

Matheus Lopes e Karla Sancio

Universidade Federal do Espírito Santo (UFES)

Disciplina: Robótica Probabilística

4 de julho de 2026

Resumo

Este relatório técnico descreve o desenvolvimento e a integração de um pipeline de aprendizado profundo para predição de ocupação espacial em Vista Superior (BEV). O projeto adapta a arquitetura MotionNet para operar com logs reais do sensor LiDAR do veículo autônomo IARA, fornecendo ao sistema de navegação relativo do ecossistema CARMEN-LCAD uma capacidade de percepção preditiva. O trabalho aborda desafios críticos de engenharia de dados, refinamentos arquiteturais contra artefatos convolucionais e avalia o modelo sob princípios de robótica probabilística. Adicionalmente, são discutidas as limitações intrínsecas da representação probabilística e a viabilidade técnica de converter mapas de calor BEV em vetores de trajetória discretos via técnicas de agrupamento e estimação, estabelecendo uma via concreta para a integração do modelo em sistemas de navegação autônoma de alto nível.

1 Introdução e Contextualização

A navegação autônoma tradicional frequentemente depende de mapeamentos estáticos e reativos. No ecossistema CARMEN-LCAD (Carnegie Mellon Robot Navigation Toolkit), utilizado pela plataforma IARA (Intelligent Autonomous Robotic Automobile), o sistema constrói mapas de ocupação instantâneos. Embora eficazes para obstáculos estáticos, esses mapas são limitados na presença de dinâmicas complexas, onde objetos móveis podem causar oclusões temporárias.

A arquitetura proposta atua como um módulo de percepção preditiva inserido entre a leitura dos sensores e o planejamento de rotas. Ao receber o histórico recente de leituras do LiDAR, a *MotionNet* estima um mapa de calor probabilístico do estado futuro do ambiente, permitindo que o robô antecipe rotas de colisão antes que o obstáculo cruze sua trajetória imediata.

2 Engenharia de Dados e Rasterização

O processo de pré-processamento converte nuvens de pontos tridimensionais (desestruturadas) em matrizes tensoriais compatíveis com redes neurais. Os logs brutos da IARA,

originalmente em formato binário `.pointcloud`, foram projetados em uma grade bidimensional (BEV) de 200×200 células, representando um raio de 20 metros ao redor do ego-veículo.

Um desafio significativo consistiu nas variações de calibração do sensor LiDAR registradas nos logs. Enquanto capturas de maio (e.g., 20230522) possuíam 5 atributos por feixe (X, Y, Z, Intensidade, Anel), logs posteriores apresentavam apenas 4. O pipeline foi adaptado com uma lógica de detecção dinâmica via divisibilidade vetorial, garantindo a robustez da conversão geométrica e filtrando reflexões infinitas ou espúrias (*NaN*). Para capturar a dinâmica do movimento, o conjunto de dados foi modelado através de janelas temporais deslizantes, agrupando 5 frames sequenciais contíguos (t_0, t_1, t_2, t_3, t_4).

3 Estrutura de Código e Implementação

O projeto foi modularizado em scripts Python distintos para garantir a reprodutibilidade e a clareza do pipeline de processamento. A implementação central foi dividida nos seguintes componentes:

- **rasterizar_bev.py**: Responsável pela ingestão direta dos arquivos binários brutos. Inclui um filtro de robustez matemático que descarta valores anômalos e converte as coordenadas contínuas (X, Y) na grade de ocupação discreta de forma paralelizada para processamento em lote de múltiplos logs.
- **model.py** e **dataset.py**: Contêm a definição formal da arquitetura da *MotionNet* em PyTorch e as classes de formatação de tensores. A estrutura gerencia o empilhamento dos canais espaciais que fornecem o viés direcional à rede.
- **treinar.py** e **calcular_metricas.py**: Controlam o ciclo de otimização auto-supervisionada via retropropagação e a validação quantitativa da rede, aplicando a função de perda de Entropia Cruzada Binária (BCE) e traduzindo probabilidades difusas em métricas de precisão.
- **gerar_visuais_finais.py**: Script de inferência unificado que percorre os logs validados, monta as janelas de contexto temporal e gera as composições gráficas finais de predição espacial e incerteza comparativa.

4 Arquitetura do Modelo e Refinamento do Decoder

A arquitetura proposta para este projeto fundamenta-se em uma topologia espacial *Encoder-Decoder*, que atua como o módulo de percepção preditiva central do sistema. A MotionNet posiciona-se no pipeline do ecossistema CARMEN-LCAD como uma camada vidente entre a aquisição bruta dos dados do sensor LiDAR e o planejador de rotas da IARA. Enquanto o CARMEN tradicionalmente constrói mapas de ocupação instantâneos e reativos, a MotionNet processa o histórico de frames para antecipar a dinâmica do ambiente, fornecendo ao sistema uma capacidade de reação proativa.

No âmbito da rede neural, o *Encoder* extrai características latentes de janelas temporais de t_0 a t_3 . O *Decoder*, por sua vez, foi alvo de refinamento: inicialmente, a utilização de convoluções transpostas (`ConvTranspose2d`) para reamostrar a resolução espacial resultou em severos *Checkerboard Artifacts* (efeito quadriculado), comuns em grades esparsas de LiDAR devido à sobreposição matemática dos *strides*.

A solução adotada consistiu em substituir essa abordagem por blocos de **Resize Convolution**. Esta técnica combina interpolação espacial (vizinho mais próximo) seguida por convoluções estáveis de passo unitário, finalizadas com ativação Sigmoide. Essa arquitetura garante que a predição no instante t_4 seja contínua, eliminando artefatos e permitindo que o sistema de navegação receba mapas de calor probabilísticos confiáveis, fundamentais para que o veículo autônomo IARA antecipe colisões e planeje trajetórias seguras ao redor de obstáculos em movimento.

5 Experimentos e Avaliação Probabilística

O processo de treinamento foi conduzido ao longo de 50 épocas, utilizando uma estratégia de otimização auto-supervisionada baseada na minimização da Entropia Cruzada Binária (BCE). A análise da evolução temporal dos pesos da rede revela um comportamento análogo a um filtro de Bayes espacial: nas primeiras épocas, a predição apresenta uma alta entropia, manifestada como uma distribuição de probabilidade difusa por toda a grade. Com o progresso das épocas, esta incerteza contraiu-se progressivamente, resultando em delineamentos nítidos sobre as trajetórias futuras prováveis dos objetos.

5.1 Estabilidade do Treinamento e Convergência

A convergência do modelo foi monitorada através da função de perda em ambos os conjuntos de treino e validação. A estabilidade observada nos gráficos de performance (ver Figura 6) confirma que a arquitetura atingiu um ponto de equilíbrio ótimo sem exibir sintomas de sobreajuste (*overfitting*). A substituição das camadas de convolução transpostas por blocos de *Resize Convolution* foi determinante para eliminar artefatos geométricos (efeito *checkerboard*), garantindo que a predição da ocupação futura preservasse a continuidade espacial necessária para a segurança da plataforma IARA.

5.2 Análise Qualitativa por Cenário

Para validar a robustez, o pipeline foi executado sobre cinco logs distintos. A amostragem visual detalhada apresentada a seguir demonstra a capacidade de generalização do modelo frente a diferentes densidades de obstáculos. Observa-se que, em situações de movimento lateral, a rede projeta "rastros" de probabilidade que antecipam a ocupação espacial futura, um comportamento que atua como uma margem de segurança probabilística intrínseca à arquitetura preditiva.

5.3 Métricas Quantitativas e Limiar de Decisão

A avaliação quantitativa foi realizada aplicando-se um limiar de confiança ($\tau = 0.15$) sobre as saídas probabilísticas do decodificador. Este limiar foi definido empiricamente para equilibrar a sensibilidade do sistema: um valor baixo o suficiente para garantir alta revocação (segurança contra colisões) e alto o suficiente para filtrar ruídos residuais do LiDAR.

A métrica de Revocação (Recall) de 60.95% demonstra que o modelo é capaz de identificar a vasta maioria das áreas de ocupação real no frame futuro. A precisão de 50.49% e o IoU de 38.15% são valores consistentes com o estado da arte para predição de grades BEV sob incerteza, onde o modelo prioriza a antecipação conservadora (falsos


Tabela 1: Avaliação Quantitativa Global ($\tau = 0.15$)

Métrica	Desempenho
Precisão (<i>Precision</i>)	50.49%
Revocação (<i>Recall</i>)	60.95%
IoU Global	38.15%


positivos em torno do objeto) em detrimento da omissão de possíveis obstáculos (falsos negativos).

6 Análise Qualitativa dos Logs


Para validar a robustez do modelo, o pipeline foi aplicado integralmente aos cinco logs selecionados. A seguir, apresentamos a amostragem visual detalhada de cada experimento, organizando o mapa de entrada, a sequência temporal e o resultado da inferência de forma individualizada para assegurar a clareza e a legibilidade dos resultados.



(a) Mapa BEV de entrada - Log 1



(b) Sequência temporal (Frames 0 a 4) - Log 1




(c) Predição e Incerteza (Inferência) - Log 1


Figura 1: Resultados detalhados obtidos no Log 1.



(a) Mapa BEV de entrada - Log 2



(b) Sequência temporal (Frames 0 a 4) - Log 2




(c) Predição e Incerteza (Inferência) - Log 2


Figura 2: Resultados detalhados obtidos no Log 2.



(a) Mapa BEV de entrada - Log 3




(b) Sequência temporal (Frames 0 a 4) - Log 3




(c) Predição e Incerteza (Inferência) - Log 3


Figura 3: Resultados detalhados obtidos no Log 3.



(a) Mapa BEV de entrada - Log 4




(b) Sequência temporal (Frames 0 a 4) - Log 4




(c) Predição e Incerteza (Inferência) - Log 4


Figura 4: Resultados detalhados obtidos no Log 4.



(a) Mapa BEV de entrada - Log 5



(b) Sequência temporal (Frames 0 a 4) - Log 5




(c) Predição e Incerteza (Inferência) - Log 5


Figura 5: Resultados detalhados obtidos no Log 5.

A análise visual consolidada dos cinco logs demonstra que a rede neural incorporou o dinamismo temporal necessário para a predição. É perceptível que, nos casos em que objetos móveis estão presentes, a região de incerteza (representada pelos tons em escala de magenta) expande-se seguindo o vetor de movimento detectado nos frames anteriores, agindo como uma margem de segurança probabilística. A capacidade do modelo em manter a nitidez da predição nos instantes de oclusão ou transição confirma a eficácia da substituição das convoluções transpostas por blocos de *Resize Convolution*, que preservaram a continuidade espacial das bordas dos obstáculos e evitaram artefatos que poderiam induzir falsos alertas em um sistema de navegação autônoma real.

7 Análise de Performance e Convergência



(a) Convergência da perda.



(b) IoU médio por log.

Figura 6: Avaliação da estabilidade do treinamento e variância da performance espacial.

O Gráfico (a) demonstra que a função de perda convergiu estavelmente ao longo das 50 épocas, sem sinais de divergência ou *overfitting*. O Gráfico (b) ilustra a robustez do modelo frente aos diferentes cenários de coleta, onde o IoU manteve-se consistente (média de 38.15%), indicando que a rede generalizou bem os padrões de movimento independente das variações de tráfego registradas em cada log da IARA.

8 Discussão sobre Limitações e Desafios de Integração

A integração da *MotionNet* ao ecossistema CARMEN-LCAD apresentou desafios técnicos relevantes, centrados principalmente na heterogeneidade dos dados sensoriais da IARA. A conversão das nuvens de pontos brutos para o formato BEV enfrentou variações de calibração entre os diferentes logs coletados, exigindo a implementação de filtros de robustez para normalizar as representações antes da inferência pela rede. Além disso, a interpretação das saídas do modelo revelou-se um desafio: como o decodificador produz uma grade de probabilidade de ocupação contínua (e não instâncias individuais de objetos), o sistema é inerentemente agnóstico à identidade dos obstáculos. Isso significa que, embora o modelo antecipe que "algum" objeto ocupará uma célula específica, ele não distingue se a ocupação provém de um pedestre, um veículo ou um artefato estático, o que exige um pós-processamento cauteloso para evitar a propagação de incertezas que poderiam induzir frenagens indevidas (falsos positivos).

9 Representação e Disponibilização de Trajetórias

Para que as previsões BEV tornem-se operacionais para outros módulos do CARMEN-LCAD (como o planejador de rotas), a representação probabilística atual deve ser transformada em dados de mais alto nível. Uma estratégia promissora consiste em aplicar algoritmos de agrupamento espacial, como o DBSCAN, sobre as células com alta probabilidade de ocupação. Ao identificar grupos contíguos de células, é possível extrair o centroide de cada obstáculo móvel detectado. Aplicando Filtros de Kalman ou estimadores de movimento sobre a evolução desses centroides ao longo dos frames preditos, torna-se viável converter a "nuvem de probabilidade" em vetores de trajetória discretos (v_x, v_y, ω) . Estes vetores, uma vez convertidos para o referencial global do robô, podem ser injetados diretamente na biblioteca de desvio de obstáculos do CARMEN-LCAD, permitindo que a navegação autônoma não apenas "veja" o futuro, mas "planeje" ativamente ao redor dos objetos em movimento.

10 Conclusões e Trabalhos Futuros

A integração da base MotionNet ao sistema IARA obteve sucesso em traduzir rastros temporais mecanicistas em mapas espaciais probabilísticos futuros. O pipeline mostrou-se resiliente às anomalias dos logs reais e a alteração estrutural no decodificador garantiu previsões suaves e confiáveis.

Como extensões futuras para o ecossistema CARMEN, as previsões BEV podem ser agrupadas via algoritmos espaciais contíguos (e.g., DBSCAN) para associar as regiões ativas a instâncias unitárias. Aplicando Filtros de Kalman sobre os centroides dessas regiões, torna-se viável a conversão da ocupação probabilística de grade para vetores rígidos de trajetória (v_x, v_y) .